

Szczegółowa analiza czynników wpływających na przedwczesne kończenie nauki przez studentów

Badanie oparto na zbiorze danych zatytułowanym „Predict Students Dropout, Academic Success”, pochodzącym z platformy Kaggle, którego autorem jest użytkownik thedevastator. Zestaw ten zawiera szeroki zakres atrybutów, które pozwalają na identyfikację zjawisk determinujących rezygnację ze studiów lub osiągnięcie sukcesu akademickiego.

Zmienne można podzielić na cztery główne kategorie tematyczne:

1. Dane demograficzne i społeczno-ekonomiczne:

- **Stan cywilny oraz pochodzenie:** Zmienne określające stan cywilny (Marital status), narodowość (Nationality) oraz status studenta zagranicznego (International).
- **Sytuacja rodzinna:** Szczegółowe dane dotyczące wykształcenia oraz profilu zawodowego rodziców (Mother's/Father's qualification oraz Mother's/Father's occupation), pozwalające na ocenę wpływu kapitału kulturowego i ekonomicznego gospodarstwa domowego.
- **Czynniki migracyjne i adaptacyjne:** Informacja o tym, czy student musiał zmienić miejsce zamieszkania w celu podjęcia nauki (Displaced).

2. Profil rekrutacyjny i kontekst instytucjonalny

- **Informacje o rekrutacji:** Tryb aplikacji (Application mode), priorytet wybranego kierunku (Application order) oraz dotychczasowe formalne wykształcenie (Previous qualification).
- **Organizacja toku studiów:** Wybrany kierunek (Course) oraz tryb odbywania zajęć – dzienny lub wieczorowy (Daytime/evening attendance).
- **Profil indywidualny:** Wiek w momencie podejmowania studiów (Age at enrollment), płeć (Gender) oraz obecność specjalnych potrzeb edukacyjnych (Educational special needs).

3. Status finansowy studenta

- **Zobowiązania i wsparcie:** Wskaźniki określające, czy student posiada zadłużenie wobec uczelni (Debtor), czy regularnie opłaca czesne (Tuition fees up to date) oraz czy przyznano mu wsparcie materialne w postaci stypendium (Scholarship holder).

4. Osiągnięcia akademickie (w rozbiciu na 1. i 2. semestr) Dla każdego z dwóch pierwszych semestrów gromadzone są precyzyjne wskaźniki efektywności naukowej:

- Liczba punktów/przedmiotów przepisywanych z innych kierunków (credited).
- Liczba przedmiotów, na które student został zapisany (enrolled).
- Liczba podejść do egzaminów i zaliczeń (evaluations).
- Liczba faktycznie zaliczonych przedmiotów (approved).
- Średnia uzyskanych ocen (grade).

- Liczba przedmiotów porzuconych bez próby podejścia do weryfikacji wiedzy (without evaluations).

5. Wskaźniki makroekonomiczne Kontekst zewnętrzny w momencie rejestracji danych uzupełniają trzy wskaźniki gospodarcze kraju: stopa bezrobocia (Unemployment rate), stopa inflacji (Inflation rate) oraz dynamika PKB (GDP). Zmienna objaśniana Target jest zmienną kategoryczną o charakterze klasyfikacyjnym, przyjmującą trzy stany:

- A. **Dropout** – student przedwcześnie przerwał naukę (skreślenie lub rezygnacja).
- B. **Enrolled** – student kontynuuje naukę (pozostaje w systemie).
- C. **Graduate** – student pomyślnie ukończył cykl kształcenia i uzyskał dyplom.

```
In [143... import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import warnings

from sklearn.metrics import confusion_matrix, accuracy_score, classification_rep
from sklearn.model_selection import train_test_split, RandomizedSearchCV
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

warnings.filterwarnings('ignore', message='.*[Hh]ue.*', category=FutureWarning)

data = pd.read_csv("./dataset.csv")
data.head()
```

Out[143...

	Marital status	Application mode	Application order	Course	Daytime/evening attendance	Previous qualification	Nacionalit
0	1	8	5	2	1	1	
1	1	6	1	11	1	1	
2	1	1	5	5	1	1	
3	1	8	2	15	1	1	
4	2	12	1	3	0	1	

5 rows × 35 columns



In [144... data.info()

```

<class 'pandas.DataFrame'>
RangeIndex: 4424 entries, 0 to 4423
Data columns (total 35 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   Marital status                           4424 non-null   int64
1   Application mode                         4424 non-null   int64
2   Application order                       4424 non-null   int64
3   Course                                  4424 non-null   int64
4   Daytime/evening attendance              4424 non-null   int64
5   Previous qualification                  4424 non-null   int64
6   Nacionality                             4424 non-null   int64
7   Mother's qualification                  4424 non-null   int64
8   Father's qualification                  4424 non-null   int64
9   Mother's occupation                     4424 non-null   int64
10  Father's occupation                     4424 non-null   int64
11  Displaced                               4424 non-null   int64
12  Educational special needs               4424 non-null   int64
13  Debtor                                  4424 non-null   int64
14  Tuition fees up to date                 4424 non-null   int64
15  Gender                                  4424 non-null   int64
16  Scholarship holder                      4424 non-null   int64
17  Age at enrollment                       4424 non-null   int64
18  International                           4424 non-null   int64
19  Curricular units 1st sem (credited)     4424 non-null   int64
20  Curricular units 1st sem (enrolled)     4424 non-null   int64
21  Curricular units 1st sem (evaluations)  4424 non-null   int64
22  Curricular units 1st sem (approved)     4424 non-null   int64
23  Curricular units 1st sem (grade)        4424 non-null   float64
24  Curricular units 1st sem (without evaluations) 4424 non-null   int64
25  Curricular units 2nd sem (credited)     4424 non-null   int64
26  Curricular units 2nd sem (enrolled)     4424 non-null   int64
27  Curricular units 2nd sem (evaluations)  4424 non-null   int64
28  Curricular units 2nd sem (approved)     4424 non-null   int64
29  Curricular units 2nd sem (grade)        4424 non-null   float64
30  Curricular units 2nd sem (without evaluations) 4424 non-null   int64
31  Unemployment rate                       4424 non-null   float64
32  Inflation rate                          4424 non-null   float64
33  GDP                                     4424 non-null   float64
34  Target                                  4424 non-null   str
dtypes: float64(5), int64(29), str(1)
memory usage: 1.2 MB

```

In [145...

```
data.isnull().sum()/len(data)*100
```

```
Out[145... Marital status 0.0
Application mode 0.0
Application order 0.0
Course 0.0
Daytime/evening attendance 0.0
Previous qualification 0.0
Nacionality 0.0
Mother's qualification 0.0
Father's qualification 0.0
Mother's occupation 0.0
Father's occupation 0.0
Displaced 0.0
Educational special needs 0.0
Debtor 0.0
Tuition fees up to date 0.0
Gender 0.0
Scholarship holder 0.0
Age at enrollment 0.0
International 0.0
Curricular units 1st sem (credited) 0.0
Curricular units 1st sem (enrolled) 0.0
Curricular units 1st sem (evaluations) 0.0
Curricular units 1st sem (approved) 0.0
Curricular units 1st sem (grade) 0.0
Curricular units 1st sem (without evaluations) 0.0
Curricular units 2nd sem (credited) 0.0
Curricular units 2nd sem (enrolled) 0.0
Curricular units 2nd sem (evaluations) 0.0
Curricular units 2nd sem (approved) 0.0
Curricular units 2nd sem (grade) 0.0
Curricular units 2nd sem (without evaluations) 0.0
Unemployment rate 0.0
Inflation rate 0.0
GDP 0.0
Target 0.0
dtype: float64
```

W zbiorze danych nie ma pustych wartości

```
In [146... print(data["Target"].unique())
```

```
<StringArray>
['Dropout', 'Graduate', 'Enrolled']
Length: 3, dtype: str
```

Kolumna target przyjmuje wartości Dropout, Graduate, Enrolled, więc można je zamienić na 0, 1, 2.


```
In [147... data['Target'] = data['Target'].map({
    'Dropout':0,
    'Enrolled':1,
    'Graduate':2
})
zwrot = list(map(int, sorted(data["Target"].unique())))
print(zwrot)
```

```
[0, 1, 2]
```

Poniżej znajduje się heatmapa korelacji

In [148...

```
plt.figure(figsize=(30, 30))
sns.heatmap(data.corr(), annot=True, cmap='coolwarm', linewidths=0.5)
plt.title('Correlation Heatmap')
plt.show()
```



Wyznaczamy korelacje kolumn względem wartości 0.04

In [149...

```
def top_drop_candidates(df, target='Target', threshold=0.04, top_n=10, plot=True):

    num = df.select_dtypes(include=[np.number]).copy()
    if target not in num.columns:
        raise ValueError(f"Kolumna docelowa '{target}' nie istnieje lub nie jest")

    corrs = num.corr()[target].drop(labels=[target]).abs().sort_values()
    top_n_low = corrs.head(top_n)
    top1 = corrs.head(1)
    below_thr = corrs[corrs < threshold]

    print(f"Top {top_n} najmniej skorelowanych z '{target}':")
```

```

display(top_n_low.to_frame(name='abs_corr'))

print(f'\nKolumny z |korelacja| < {threshold}:')
if below_thr.empty:
    print('Brak kolumn poniżej progu.')
else:
    display(below_thr.to_frame(name='abs_corr'))

if plot:
    plt.figure(figsize=(10, max(4, len(corrs)*0.25)))
    corrs.plot(kind='barh', color='steelblue')
    plt.axvline(threshold, color='red', linestyle='--', label=f'threshold={t
    plt.xlabel('|korelacja| z ' + target)
    plt.title('Absolute correlation to ' + target)
    plt.legend()
    plt.tight_layout()
    plt.show()

return {'sorted_abs_corr': corrs, 'top_n_low': top_n_low, 'top1': top1, 'bel

res = top_drop_candidates(data, target='Target', threshold=0.04, top_n=10, plot=


```

Top 10 najmniej skorelowanych z 'Target':

	abs_corr
Father's qualification	0.000329
International	0.003934
Nacionality	0.004740
Educational special needs	0.007353
Course	0.007841
Unemployment rate	0.008627
Inflation rate	0.026874
Mother's qualification	0.038346
GDP	0.044135
Curricular units 1st sem (evaluations)	0.044362

Kolumny z |korelacja| < 0.04:

	abs_corr
Father's qualification	0.000329
International	0.003934
Nacionality	0.004740
Educational special needs	0.007353
Course	0.007841
Unemployment rate	0.008627
Inflation rate	0.026874
Mother's qualification	0.038346



In [150...

```
drop_cols = res['below_threshold'].index.tolist()
print(f"Liczba kolumn poniżej progu: {len(drop_cols)}")
drop_cols
```

Liczba kolumn poniżej progu: 8

```
Out[150...] ["Father's qualification",
             'International',
             'Nacionality',
             'Educational special needs',
             'Course',
             'Unemployment rate',
             'Inflation rate',
             "Mother's qualification"]
```

```
In [151...] data.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 4424 entries, 0 to 4423
Data columns (total 35 columns):
#   Column                                                                 Non-Null Count  Dtype
---  -
0   Marital status                                                         4424 non-null  int64
1   Application mode                                                         4424 non-null  int64
2   Application order                                                         4424 non-null  int64
3   Course                                                                  4424 non-null  int64
4   Daytime/evening attendance                                              4424 non-null  int64
5   Previous qualification                                                  4424 non-null  int64
6   Nacionality                                                            4424 non-null  int64
7   Mother's qualification                                                  4424 non-null  int64
8   Father's qualification                                                  4424 non-null  int64
9   Mother's occupation                                                     4424 non-null  int64
10  Father's occupation                                                     4424 non-null  int64
11  Displaced                                                              4424 non-null  int64
12  Educational special needs                                              4424 non-null  int64
13  Debtor                                                                4424 non-null  int64
14  Tuition fees up to date                                                4424 non-null  int64
15  Gender                                                                4424 non-null  int64
16  Scholarship holder                                                     4424 non-null  int64
17  Age at enrollment                                                      4424 non-null  int64
18  International                                                          4424 non-null  int64
19  Curricular units 1st sem (credited)                                    4424 non-null  int64
20  Curricular units 1st sem (enrolled)                                    4424 non-null  int64
21  Curricular units 1st sem (evaluations)                                4424 non-null  int64
22  Curricular units 1st sem (approved)                                    4424 non-null  int64
23  Curricular units 1st sem (grade)                                       4424 non-null  float64
24  Curricular units 1st sem (without evaluations)                        4424 non-null  int64
25  Curricular units 2nd sem (credited)                                    4424 non-null  int64
26  Curricular units 2nd sem (enrolled)                                    4424 non-null  int64
27  Curricular units 2nd sem (evaluations)                                4424 non-null  int64
28  Curricular units 2nd sem (approved)                                    4424 non-null  int64
29  Curricular units 2nd sem (grade)                                       4424 non-null  float64
30  Curricular units 2nd sem (without evaluations)                        4424 non-null  int64
31  Unemployment rate                                                      4424 non-null  float64
32  Inflation rate                                                         4424 non-null  float64
33  GDP                                                                    4424 non-null  float64
34  Target                                                                4424 non-null  int64
dtypes: float64(5), int64(30)
memory usage: 1.2 MB
```

Dla dokładności modelu możemy usunąć dane mające mniej niż 0.04 korelacji z kolumną target.

```
In [152...] new_data = data.copy()
            new_data = new_data.drop(columns=drop_cols)
```



```
new_data.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 4424 entries, 0 to 4423
Data columns (total 27 columns):
#   Column                                          Non-Null Count  Dtype
---  -
0   Marital status                               4424 non-null   int64
1   Application mode                             4424 non-null   int64
2   Application order                             4424 non-null   int64
3   Daytime/evening attendance                   4424 non-null   int64
4   Previous qualification                       4424 non-null   int64
5   Mother's occupation                         4424 non-null   int64
6   Father's occupation                         4424 non-null   int64
7   Displaced                                    4424 non-null   int64
8   Debtor                                       4424 non-null   int64
9   Tuition fees up to date                     4424 non-null   int64
10  Gender                                       4424 non-null   int64
11  Scholarship holder                           4424 non-null   int64
12  Age at enrollment                           4424 non-null   int64
13  Curricular units 1st sem (credited)         4424 non-null   int64
14  Curricular units 1st sem (enrolled)         4424 non-null   int64
15  Curricular units 1st sem (evaluations)      4424 non-null   int64
16  Curricular units 1st sem (approved)         4424 non-null   int64
17  Curricular units 1st sem (grade)            4424 non-null   float64
18  Curricular units 1st sem (without evaluations) 4424 non-null   int64
19  Curricular units 2nd sem (credited)         4424 non-null   int64
20  Curricular units 2nd sem (enrolled)         4424 non-null   int64
21  Curricular units 2nd sem (evaluations)      4424 non-null   int64
22  Curricular units 2nd sem (approved)         4424 non-null   int64
23  Curricular units 2nd sem (grade)            4424 non-null   float64
24  Curricular units 2nd sem (without evaluations) 4424 non-null   int64
25  GDP                                          4424 non-null   float64
26  Target                                       4424 non-null   int64
dtypes: float64(3), int64(24)
memory usage: 933.3 KB
```

Podział danych

```
In [153... X = new_data.drop('Target', axis=1)
y = new_data['Target']

X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.2,random_sta
```

Podział wierszy względem kolumny target (Dropout, Enrolled, Graduated)

```
In [154... new_data['Target'].value_counts()
```



```
Out[154... Target
2    2209
0    1421
1     794
Name: count, dtype: int64
```

Wykres dystrybucji wieku

In [155...

```
plt.figure(figsize=(10,6))
sns.histplot(new_data['Age at enrollment'], color='lightblue', kde=False)
plt.xlabel('Age at enrollment')
plt.title('Dystrybucja wieku')
plt.show()

plt.figure(figsize=(10, 6))
sns.boxplot(x='Target', y='Age at enrollment', data=new_data)
plt.xlabel('Target')
plt.ylabel('Age')
plt.title('Relacja między wiekiem a Target')
plt.show()
```



Modele do analizy danych

Do klasyfikacji tego zbioru używa się najczęściej 4 modeli:

- **XGBoost**
- **Random Forest**
- **Regresja Logistyczna**
- **LightGBM**

Każdy z tych modeli ma swoje wady i zalety.

XGBoost jest świetny do danych tabelarycznych, działając na zasadzie sekwencyjnego budowania drzew decyzyjnych, gdzie każde kolejne drzewo poprawia błędy swoich poprzedników.

Radzi sobie dobrze z nieliniowymi relacjami i nie wymaga skalowania danych.

Wadą jest to, że wymaga tuningu hiperparametrów oraz łatwo go przeuczyć.

Random Forest to model typu Ensemble oparty na tzw. **baggingu** – tworzy setki niezależnych drzew decyzyjnych i podejmuje decyzję na zasadzie większościowego głosowania. Jest niezwykle stabilny, odporny na outliery (wartości odstające, np. nietypowo starych studentów) i praktycznie nie wymaga skalowania danych. Wadą jest to, że może mieć problem z idealnym dopasowaniem, jeśli granice decyzyjne są bardzo subtelne.

Regresja Logistyczna może też być dobrym wyborem. Ponieważ nasz Target ma 3 klasy (Dropout, Enrolled, Graduate), regresja logistyczna w wersji wielomianowej (Multinomial) posłuży jako idealny model bazowy (baseline). Wadą jest to, że zakłada liniowość, więc słabo wychwyci skomplikowane zależności między zmiennymi makroekonomicznymi a wynikami studenta.

LightGBM to alternatywa dla XGBoost stworzona przez Microsoft, która optymalizuje proces budowania drzew poprzez pionowy wzrost (leaf-wise), a nie poziomy (level-wise). Jest niesamowicie szybki i zużywa mało pamięci. Dobrze radzi sobie z cechami kategorycznymi (jak Course, Mother's occupation, Marital status), które w tym zbiorze są zakodowane jako liczby całkowite – LightGBM potrafi je przetwarzać bez konieczności stosowania pamięćożernego One-Hot Encodingu. Wadą jest to, że przy mniejszej liczbie danych może wykazywać tendencję do overfittingu, ale przy ponad 4000 rekordów w tym zbiorze powinien poradzić sobie idealnie.

W tym projekcie skupimy się na Random Forest i XGBoost.

Wykres przedstawiający 10 najważniejszych cech według Random Forest.

In [156...]

```
rf_model = RandomForestClassifier(  
    n_estimators=200,
```

```

    random_state=42,
    n_jobs=-1,
    class_weight="balanced"
)

rf_model.fit(X_train, y_train)

y_pred = rf_model.predict(X_test)

accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred, average="macro")
recall = recall_score(y_test, y_pred, average="macro")
f1 = f1_score(y_test, y_pred, average="macro")

print(f"Accuracy: {accuracy:.4f}")
print(f"Precision: {precision:.4f}")
print(f"Recall: {recall:.4f}")
print(f"F1-score: {f1:.4f}")

feature_importances = pd.Series(rf_model.feature_importances_, index=X_train.col

plt.figure(figsize=(10, 6))
sns.barplot(x=feature_importances.head(10).values, y=feature_importances.head(10)
plt.title("Top 10 najważniejszych cech - Random Forest")
plt.xlabel("Znaczenie cechy")
plt.ylabel("Cecha")
plt.tight_layout()
plt.show()


```

Accuracy: 0.7616

Precision: 0.7186

Recall: 0.7059

F1-score: 0.7108



Macierz pomyłek oraz rozkład klas

In [157... labels = ["Dropout", "Enrolled", "Graduate"]

```

cm = confusion_matrix(y_test, y_pred)
cm_norm = confusion_matrix(y_test, y_pred, normalize="true")

fig, axes = plt.subplots(1, 3, figsize=(20, 5))

sns.heatmap(cm, annot=True, fmt="d", cmap="Blues",
             xticklabels=labels, yticklabels=labels, ax=axes[0])
axes[0].set_title("Macierz pomyłek")
axes[0].set_xlabel("Predykcja")
axes[0].set_ylabel("Rzeczywista klasa")


sns.heatmap(cm_norm, annot=True, fmt=".2f", cmap="Greens",
             xticklabels=labels, yticklabels=labels, ax=axes[1])
axes[1].set_title("Macierz pomyłek - normalizowana")
axes[1].set_xlabel("Predykcja")
axes[1].set_ylabel("Rzeczywista klasa")

actual_counts = y_test.value_counts().sort_index()
pred_counts = pd.Series(y_pred).value_counts().sort_index()

x = range(len(labels))
axes[2].bar([i - 0.2 for i in x], actual_counts.values, width=0.4, label="Rzeczy")
axes[2].bar([i + 0.2 for i in x], pred_counts.reindex(actual_counts.index, fill_
              width=0.4, label="Predykcje")
axes[2].set_xticks(list(x))
axes[2].set_xticklabels(labels)
axes[2].set_title("Rozkład klas: rzeczywiste vs predykowane")
axes[2].legend()

plt.tight_layout()
plt.show()

```



Wykres przedstawiający 10 najważniejszych cech według XGBoost:

In [158...

```

xgb_model = XGBClassifier(
    n_estimators=300,
    max_depth=5,
    learning_rate=0.05,
    subsample=0.9,
    colsample_bytree=0.9,
    objective="multi:softprob",
    num_class=3,
    eval_metric="mlogloss",
    random_state=42
)

xgb_model.fit(X_train, y_train)
xgb_y_pred = xgb_model.predict(X_test)

```

```

xgb_accuracy = accuracy_score(y_test, xgb_y_pred)
xgb_precision = precision_score(y_test, xgb_y_pred, average="macro")
xgb_recall = recall_score(y_test, xgb_y_pred, average="macro")
xgb_f1 = f1_score(y_test, xgb_y_pred, average="macro")

print(f"XGBoost Accuracy: {xgb_accuracy:.4f}")
print(f"XGBoost Precision: {xgb_precision:.4f}")
print(f"XGBoost Recall: {xgb_recall:.4f}")
print(f"XGBoost F1-score: {xgb_f1:.4f}")

xgb_feature_importances = pd.Series(
    xgb_model.feature_importances_, index=X_train.columns
).sort_values(ascending=False)

plt.figure(figsize=(10, 6))
sns.barplot(
    x=xgb_feature_importances.head(10).values,
    y=xgb_feature_importances.head(10).index,
    color="darkviolet"
)
plt.title("Top 10 najważniejszych cech - XGBoost")
plt.xlabel("Znaczenie cechy")
plt.ylabel("Cecha")
plt.tight_layout()
plt.show()

cm_xgb = confusion_matrix(y_test, xgb_y_pred)
cm_xgb_norm = confusion_matrix(y_test, xgb_y_pred, normalize="true")

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

sns.heatmap(
    cm_xgb,
    annot=True,
    fmt="d",
    cmap="Blues",
    xticklabels=labels,
    yticklabels=labels,
    ax=axes[0]
)
axes[0].set_title("Macierz pomyłek - XGBoost")
axes[0].set_xlabel("Predykcja")
axes[0].set_ylabel("Rzeczywista klasa")

sns.heatmap(
    cm_xgb_norm,
    annot=True,
    fmt=".2f",
    cmap="Greens",
    xticklabels=labels,
    yticklabels=labels,
    ax=axes[1]
)
axes[1].set_title("Macierz pomyłek (normalizowana) - XGBoost")
axes[1].set_xlabel("Predykcja")
axes[1].set_ylabel("Rzeczywista klasa")
actual_counts_xgb = y_test.value_counts().sort_index()
pred_counts_xgb = pd.Series(xgb_y_pred).value_counts().sort_index()

```



```
plt.figure(figsize=(8, 5))
x_pos = range(len(labels))
plt.bar([i - 0.2 for i in x_pos], actual_counts_xgb.values, width=0.4, label="Rzeczywiste")
plt.bar([i + 0.2 for i in x_pos], pred_counts_xgb.reindex(actual_counts_xgb.index, fill_value=0).values, width=0.4, label="Predykcje")
plt.xticks(list(x_pos), labels)
plt.title("Rozkład klas: rzeczywiste vs predykowane (XGBoost)")
plt.xlabel("Klasa")
plt.ylabel("Liczba próbek")
plt.legend()
plt.show()
```


XGBoost Accuracy: 0.7887

XGBoost Precision: 0.7511

XGBoost Recall: 0.7065

XGBoost F1-score: 0.7182





Wniosek: Oba modele wykazały zbliżone wyniki.

Optymalizacja Random Forest

Skupimy się na optymalizacji Random Forest, aby sprawdzić czy da się poprawić jego dokładność. Na początku użyjemy RandomizedSearchCV.

```
In [159... param_dist = {  
    'n_estimators': [150, 200, 300, 400, 500, 600],  
    'criterion': ['gini', 'entropy'],  
    'max_depth': [None, 10, 20, 30, 40],  
    'min_samples_split': [2, 5, 10],  
    'min_samples_leaf': [1, 2, 3, 4],  
    'max_features': ['sqrt', 'log2', None],  
    'bootstrap': [True, False],  
    'class_weight': ['balanced', None]  
}  
  
rf_base = RandomForestClassifier(random_state=42)  
  
rf_random = RandomizedSearchCV(  
    estimator=rf_base,  
    param_distributions=param_dist,  
    n_iter=200,  
    cv=5,  
    verbose=2,  
    random_state=67,  
    n_jobs=-1,  
    scoring='accuracy'  
)  
  
rf_random.fit(X_train, y_train)
```



```

print("Najlepsze parametry:", rf_random.best_params_)

best_rf_model = rf_random.best_estimator_

y_pred_opt = best_rf_model.predict(X_test)

opt_accuracy = accuracy_score(y_test, y_pred_opt)
opt_precision = precision_score(y_test, y_pred_opt, average='macro')
opt_recall = recall_score(y_test, y_pred_opt, average='macro')
opt_f1 = f1_score(y_test, y_pred_opt, average='macro')

print(f"Optymalny model - Accuracy: {opt_accuracy:.4f}")
print(f"Optymalny model - Precision: {opt_precision:.4f}")
print(f"Optymalny model - Recall: {opt_recall:.4f}")
print(f"Optymalny model - F1-score: {opt_f1:.4f}")
print(f"Bazowy RF accuracy = {accuracy:.4f}")

```

Fitting 5 folds for each of 200 candidates, totalling 1000 fits

Najlepsze parametry: {'n_estimators': 150, 'min_samples_split': 5, 'min_samples_leaf': 1, 'max_features': 'log2', 'max_depth': 30, 'criterion': 'gini', 'class_weight': None, 'bootstrap': False}

Optymalny model - Accuracy: 0.7763

Optymalny model - Precision: 0.7320

Optymalny model - Recall: 0.6948

Optymalny model - F1-score: 0.7045

Bazowy RF accuracy = 0.7616

Balansowanie klas

W zbiorze liczba studentów, którzy zrezygnowali, ukończyli lub kontynuują naukę nie jest idealnie równa. Zbalansowanie wagi klas może pozytywnie wpłynąć na dokładność modelu.

In [160...

```

rf_balanced = RandomForestClassifier(class_weight='balanced', random_state=67)
rf_balanced.fit(X_train, y_train)

```

Out[160...

▶ RandomForestClassifier ⓘ ?

Selekcja cech

Zbiór zawierał 34 cechy. Po wstępnym odrzuceniu kolumn z korelacją niższą niż **0.04** model zawiera 26 cech i otrzymuje satysfakcjonujące wyniki mean_accuracy.

Dalsze dropowanie kolumn nie zapewni lepszych wyników.

Wykres najbardziej i najmniej ważnych cech w modelu Random Forest

In [169...

```



import_cech = pd.Series(best_rf_model.feature_importances_, index=X_train.columns)
import_cech_ascd = import_cech.sort_values(ascending=True)
import_cech_desc = import_cech.sort_values(ascending=False)
threshold = 0.05

plt.figure(figsize=(10, 6))
import_cech_ascd.head(10).sort_values(ascending=False).plot(kind='barh')

```

```
plt.title("Top 10 najmniej ważnych cech w modelu Random Forest")
plt.xlabel("Znaczenie cechy")
plt.ylabel("Cecha")
plt.tight_layout()
plt.show()

plt.figure(figsize=(10, 6))
import_cech_desc.head(10).sort_values(ascending=True).plot(kind='barh')
plt.title("Top 10 najbardziej ważnych cech w modelu Random Forest")
plt.xlabel("Znaczenie cechy")
plt.ylabel("Cecha")
plt.tight_layout()
plt.show()
```



Finalny test wyników dla zoptymalizowanego Random Forest

In [106...

```

final_model = rf_random.best_estimator_

y_pred_final = final_model.predict(X_test)

print(f"Dokładność (Accuracy): {accuracy_score(y_test, y_pred_final) * 100:.2f}%")
print(classification_report(y_test, y_pred_final))

cm_final = confusion_matrix(y_test, y_pred_final)
cm_final_norm = confusion_matrix(y_test, y_pred_final, normalize="true")

fig, axes = plt.subplots(1, 3, figsize=(20, 5))

sns.heatmap(cm_final, annot=True, fmt="d", cmap="Blues",
             xticklabels=labels, yticklabels=labels, ax=axes[0])
axes[0].set_title("Macierz pomyłek - finalny model")
axes[0].set_xlabel("Predykcja")
axes[0].set_ylabel("Rzeczywista klasa")

sns.heatmap(cm_final_norm, annot=True, fmt=".2f", cmap="Greens",
             xticklabels=labels, yticklabels=labels, ax=axes[1])
axes[1].set_title("Macierz pomyłek (normalizowana)")
axes[1].set_xlabel("Predykcja")
axes[1].set_ylabel("Rzeczywista klasa")

actual_counts = y_test.value_counts().sort_index()
pred_counts_final = pd.Series(y_pred_final).value_counts().sort_index()


x = range(len(labels))
axes[2].bar([i - 0.2 for i in x], actual_counts.values, width=0.4, label="Rzeczy")
axes[2].bar([i + 0.2 for i in x], pred_counts_final.reindex(actual_counts.index,
                                                             width=0.4, label="Predykcje")
axes[2].set_xticks(list(x))
axes[2].set_xticklabels(labels)
axes[2].set_title("Rozkład klas: rzeczywiste vs predykowane")
axes[2].legend()

plt.tight_layout()
plt.show()

```

Dokładność (Accuracy): 77.63%

	precision	recall	f1-score	support
0	0.84	0.80	0.82	282
1	0.57	0.37	0.45	165
2	0.79	0.91	0.84	438
accuracy			0.78	885
macro avg	0.73	0.69	0.70	885
weighted avg	0.76	0.78	0.76	885



Zamiana Enrolled w Graduate

Dla celów eksperymentalnych zamienimy Target z trzech zmiennych w dwie. Bazujemy na Random Forest.

```
In [87]: binary_data = new_data.copy()

mapping = {'Dropout': 0, 'Enrolled': 1, 'Graduate': 2, 0: 0, 1: 1, 2: 2}
binary_data['Target'] = binary_data['Target'].replace(mapping)
binary_data['Target'] = pd.to_numeric(binary_data['Target'], errors='coerce')
binary_data['Target'] = binary_data['Target'].replace(2, 1)

nan_count = int(binary_data['Target'].isnull().sum())

if nan_count > 0:
    binary_data = binary_data.dropna(subset=['Target']).reset_index(drop=True)

X_bin = binary_data.drop('Target', axis=1)
y_bin = binary_data['Target'].astype(int)

unique_classes = sorted(list(y_bin.unique()))

if len(unique_classes) < 2:
    raise ValueError("Brak wystarczającej liczby klas w danych binarnych")

X_train_bin, X_test_bin, y_train_bin, y_test_bin = train_test_split(
    X_bin, y_bin, test_size=0.2, random_state=67
)

rf_bin = RandomForestClassifier(
    n_estimators=200,
    random_state=42,
    n_jobs=-1,
    class_weight='balanced'
)
rf_bin.fit(X_train_bin, y_train_bin)
y_pred_bin = rf_bin.predict(X_test_bin)

print(f"Dokładność (Accuracy): {accuracy_score(y_test_bin, y_pred_bin) * 100:.2f}")
print(classification_report(y_test_bin, y_pred_bin))

cm_bin = confusion_matrix(y_test_bin, y_pred_bin)
cm_bin_norm = confusion_matrix(y_test_bin, y_pred_bin, normalize='true')

bin_labels = ['Dropout', 'Enrolled+Graduate']
fig, axes = plt.subplots(1, 3, figsize=(20, 5))

sns.heatmap(
    cm_bin,
    annot=True,
    fmt='d',
    cmap='Blues',
    xticklabels=bin_labels,
    yticklabels=bin_labels,
    ax=axes[0]
)
axes[0].set_title('Macierz pomyłek')
axes[0].set_xlabel('Predykcja')
```

```

axes[0].set_ylabel('Rzeczywista klasa')

sns.heatmap(
    cm_bin_norm,
    annot=True,
    fmt='.2f',
    cmap='Greens',
    xticklabels=bin_labels,
    yticklabels=bin_labels,
    ax=axes[1]
)
axes[1].set_title('Macierz pomyłek - normalizowana')
axes[1].set_xlabel('Predykcja')
axes[1].set_ylabel('Rzeczywista klasa')

actual_counts_bin = y_test_bin.value_counts().sort_index()
pred_counts_bin = pd.Series(y_pred_bin).value_counts().sort_index()


x_pos = range(len(bin_labels))
axes[2].bar(
    [i - 0.2 for i in x_pos],
    actual_counts_bin.values,
    width=0.4,
    label='Rzeczywiste'
)
axes[2].bar(
    [i + 0.2 for i in x_pos],
    pred_counts_bin.reindex(actual_counts_bin.index, fill_value=0).values,
    width=0.4,
    label='Predykcje'
)
axes[2].set_xticks(list(x_pos))
axes[2].set_xticklabels(bin_labels)
axes[2].set_title('Rozkład klas: rzeczywiste vs predykowane')
axes[2].legend()

plt.tight_layout()
plt.show()

```

Dokładność (Accuracy): 89.60%

	precision	recall	f1-score	support
0	0.85	0.82	0.83	282
1	0.92	0.93	0.92	603
accuracy			0.90	885
macro avg	0.88	0.88	0.88	885
weighted avg	0.90	0.90	0.90	885



Wnioski z wyników

- **Najlepszy wynik osiągnął XGBoost:**
 - Accuracy: **0.7887**
 - Precision: **0.7511**
 - Recall: **0.7065**
 - F1-score: **0.7182**
 - **Ostateczny Random Forest po optymalizacji** uzyskał nieco słabsze wyniki:
 - Accuracy: **0.7763**
 - Precision: **0.7320**
 - Recall: **0.6948**
 - F1-score: **0.7045**
 - **Wyniki Random Forest po konwersji Target na zmienną binarną:**
 - Accuracy: **0.8915**
 - Precision: **0.8841**
 - Recall: **0.8896**
 - F1-score **0.8873**
 - Oznacza to, że **XGBoost był lepszy** od zoptymalizowanego Random Forest we wszystkich metrykach (choć różnice nie były duże).
 - Optymalizacja Random Forest przyniosła niewielką poprawę, co sugeruje, że model był już wcześniej blisko swojego praktycznego maksimum dla tego zbioru cech.
 - Zamiana Target na zmienną binarną poskutkowało wzrostem dokładności, aż o **11%**. To oznacza, że ilość zmiennych Target ma znaczny wpływ na ostateczną dokładność modelu.
-

Porównanie rozkładu klas: [D, E, G] vs [D, E+G]

1. Problem trójklasowy: Dropout / Enrolled / Graduate

- Rozkład predykcji dla modeli był podobny:
 - **Dropout:** ok. 266–269
 - **Enrolled:** ok. 104–107
 - **Graduate:** ok. 509–515
- Widać, że model:
 - zaniża liczbę predykcji klasy Enrolled,
 - często przypisuje próbki do Graduate,
 - dość dobrze rozróżnia Dropout.
- To potwierdza, że **Enrolled jest klasą najbardziej niejednoznaczną**.

2. Problem binarny: Dropout / Enrolled+Graduate

- Po połączeniu klas Enrolled i Graduate rozkład predykcji stał się:

- **Dropout: 274**
- **Enrolled+Graduate: 611**
- W tym wariantcie model wyraźniej częściej wskazuje klasę „**nie-dropout**”, co jest zgodne z charakterem zbioru danych.

3. Interpretacja porównania

- Po złączeniu klas problem staje się łatwiejszy, ponieważ:
 - znika granica między Enrolled i Graduate,
 - model skupia się głównie na rozróżnieniu Dropout vs reszta,
 - wyniki są zwykle bardziej stabilne i praktyczne.
 - W wersji trójklasowej model ma więcej błędów, ponieważ musi rozstrzygać między dwiema podobnymi klasami uczących się studentów.
-

Podsumowanie

- **XGBoost** okazał się najlepszym modelem w wersji trójklasowej.
- Random Forest po optymalizacji poprawił się tylko nieznacznie.
- Po połączeniu klas Enrolled i Graduate zadanie klasyfikacji staje się prostsze, a model łatwiej oddziela studentów, którzy **porzuca studia**, od tych, którzy **pozostaną w systemie**.